

OceanMind - Visao Computacional Aplicada ao Monitoramento Oceanico via Dados Espaciais

FIAP - Global Solution 2026
Applied Computer Vision

Integrantes

Bryan Willian - RM 551305

Felipe Terra - RM 99405

Gabriel Doms - RM 98630

Lucas Vassao - RM 98607

Pedro Bicas - RM 99534

Introducao

O OceanMind e uma proposta de plataforma para inteligencia oceanica e previsao climatica baseada em dados espaciais, climaticos e oceanicos. Neste modulo da disciplina Applied Computer Vision, o foco esta na classificacao de imagens oceanicas/satelitais para apoiar a leitura automatizada de padroes ambientais.

A conexao com a Industria Espacial ocorre pelo uso conceitual de observacao da Terra: imagens produzidas por sensores orbitais podem ser usadas para monitorar areas maritimas, regioes costeiras, formacoes de nuvens, tempestades, concentracoes de algas e possiveis anomalias termicas.

Definicao do problema

O problema de visao computacional foi definido como uma tarefa de classificacao multiclasse. A entrada do modelo e uma imagem RGB de uma cena oceanica/satelital e a saida e uma das categorias ambientais usadas pelo projeto.

As classes do dataset sao: algas, anomalia_termica, nuvens, oceano_normal, tempestade. Essa classificacao representa uma etapa inicial de triagem visual, nao uma previsao climatica completa.

Dataset

O dataset usado na ultima execucao registrada foi dataset_real. Tipo registrado: real_nasa_gibs_weak_labels.

Quando usado o fluxo real, as imagens sao baixadas do NASA GIBS via WMS. As classes sao montadas por camada, regioao e data: true color para oceano, nuvens e tempestade; clorofila-a para algas; temperatura da superficie do mar para anomalia_termica.

Esses rotulos reais sao aproximados e precisam de revisao visual, pois a origem via regioao/camada nao garante anotacao perfeita de cada imagem. O projeto inclui uma folha de contato para apoiar essa revisao.

A entrega final foi mantida com o dataset real para evitar mistura com dados artificiais.

Pre-processamento

As imagens sao organizadas em subpastas por classe, o que permite o uso de image_dataset_from_directory. O script de download real ja cria pastas train, validation e test.

Durante o carregamento, todas sao redimensionadas para o tamanho informado no treinamento. Na execucao final, foi usado 160x160 pixels.

A normalizacao dos pixels e feita dentro das arquiteturas por meio da camada Rescaling(1./255). Assim, as imagens entram no modelo em escala padronizada sem alterar os arquivos originais do dataset.

Arquiteturas CNN

As duas redes foram criadas do zero com TensorFlow/Keras. Nenhuma usa transfer learning, pesos externos ou arquitetura pre-treinada.

A CNN v1 funciona como baseline. Ela usa tres blocos Conv2D e MaxPooling2D, seguidos de Flatten, Dense, Dropout e camada final Dense com softmax.

A CNN v2 é mais profunda e regularizada. Ela usa blocos com Conv2D, BatchNormalization, MaxPooling2D e Dropout, além de GlobalAveragePooling2D antes das camadas densas finais. A principal diferença está na maior regularização e no uso de pooling global em vez de Flatten.

Treinamento

O treinamento foi configurado para até 12 épocas, otimizador Adam, função de perda `categorical_crossentropy` e métrica `accuracy`.

Foram usados `EarlyStopping` com restauração dos melhores pesos e `ReduceLROnPlateau` para reduzir a taxa de aprendizado quando a `loss` de validação parasse de melhorar.

Resultados

A CNN v1 obteve `test accuracy` de 90.62% e `test loss` de 0.238404. A CNN v2 obteve `test accuracy` de 46.88% e `test loss` de 1.578710.

Os gráficos de `accuracy/loss`, as matrizes de confusão e os relatórios de classificação foram salvos automaticamente na pasta `reports`.

O `classification report` salvo detalha `precision`, `recall` e `f1-score` por classe. No dataset real atual, o desempenho ficou melhor em `algas` e `anomalia_termica`, mas houve confusão relevante entre `nuvens`, `oceano_normal` e `tempestade`.

Comparação entre modelos

Na execução atual, o melhor modelo foi CNN v1, com acurácia de teste de 90.62%.

O critério de 88% foi atendido pelo melhor modelo (CNN v1). Ainda assim, o resultado deve ser interpretado com cautela, porque parte dos rótulos foi definida por camada, região e data, e não por anotação manual imagem a imagem.

Também há limitações de escala: o dataset final ficou com 208 imagens após limpeza, o que ainda é pouco para imagens satelitais reais. A variação de sensor, data, cobertura de nuvens, paleta de camada científica e composição visual torna o problema difícil.

Para melhorar, o caminho mais consistente é ampliar o número de imagens, revisar manualmente amostras incorretas, balancear melhor regiões e datas, usar `data augmentation` e treinar por mais épocas após a limpeza dos rótulos.

Demonstração funcional

A demonstração foi implementada em Streamlit no arquivo `app.py`. O comando de execução é: `streamlit run app.py`.

O app permite selecionar a CNN treinada, enviar uma imagem e visualizar a classe prevista, a confiança da predição e as probabilidades por classe.


[INSERIR PRINT DO APP STREAMLIT AQUI, SE O PROFESSOR EXIGIR EVIDÊNCIA VISUAL DA EXECUÇÃO]

Conclusao


A entrega demonstra um pipeline completo de classificacao de imagens aplicado ao contexto espacial/oceanico: geracao de dataset, pre-processamento, treino de duas CNNs do zero, avaliacao quantitativa, comparacao entre modelos e demonstracao funcional.

O projeto atende ao objetivo academico da disciplina. Como continuidade, o principal passo tecnico seria ampliar o dataset real e revisar manualmente os rotulos para aumentar a robustez em condicoes menos controladas.


Amostras do dataset real




Historico de treinamento - CNN v1



Matriz de confusao - CNN v1



Historico de treinamento - CNN v2



Matriz de confusao - CNN v2

